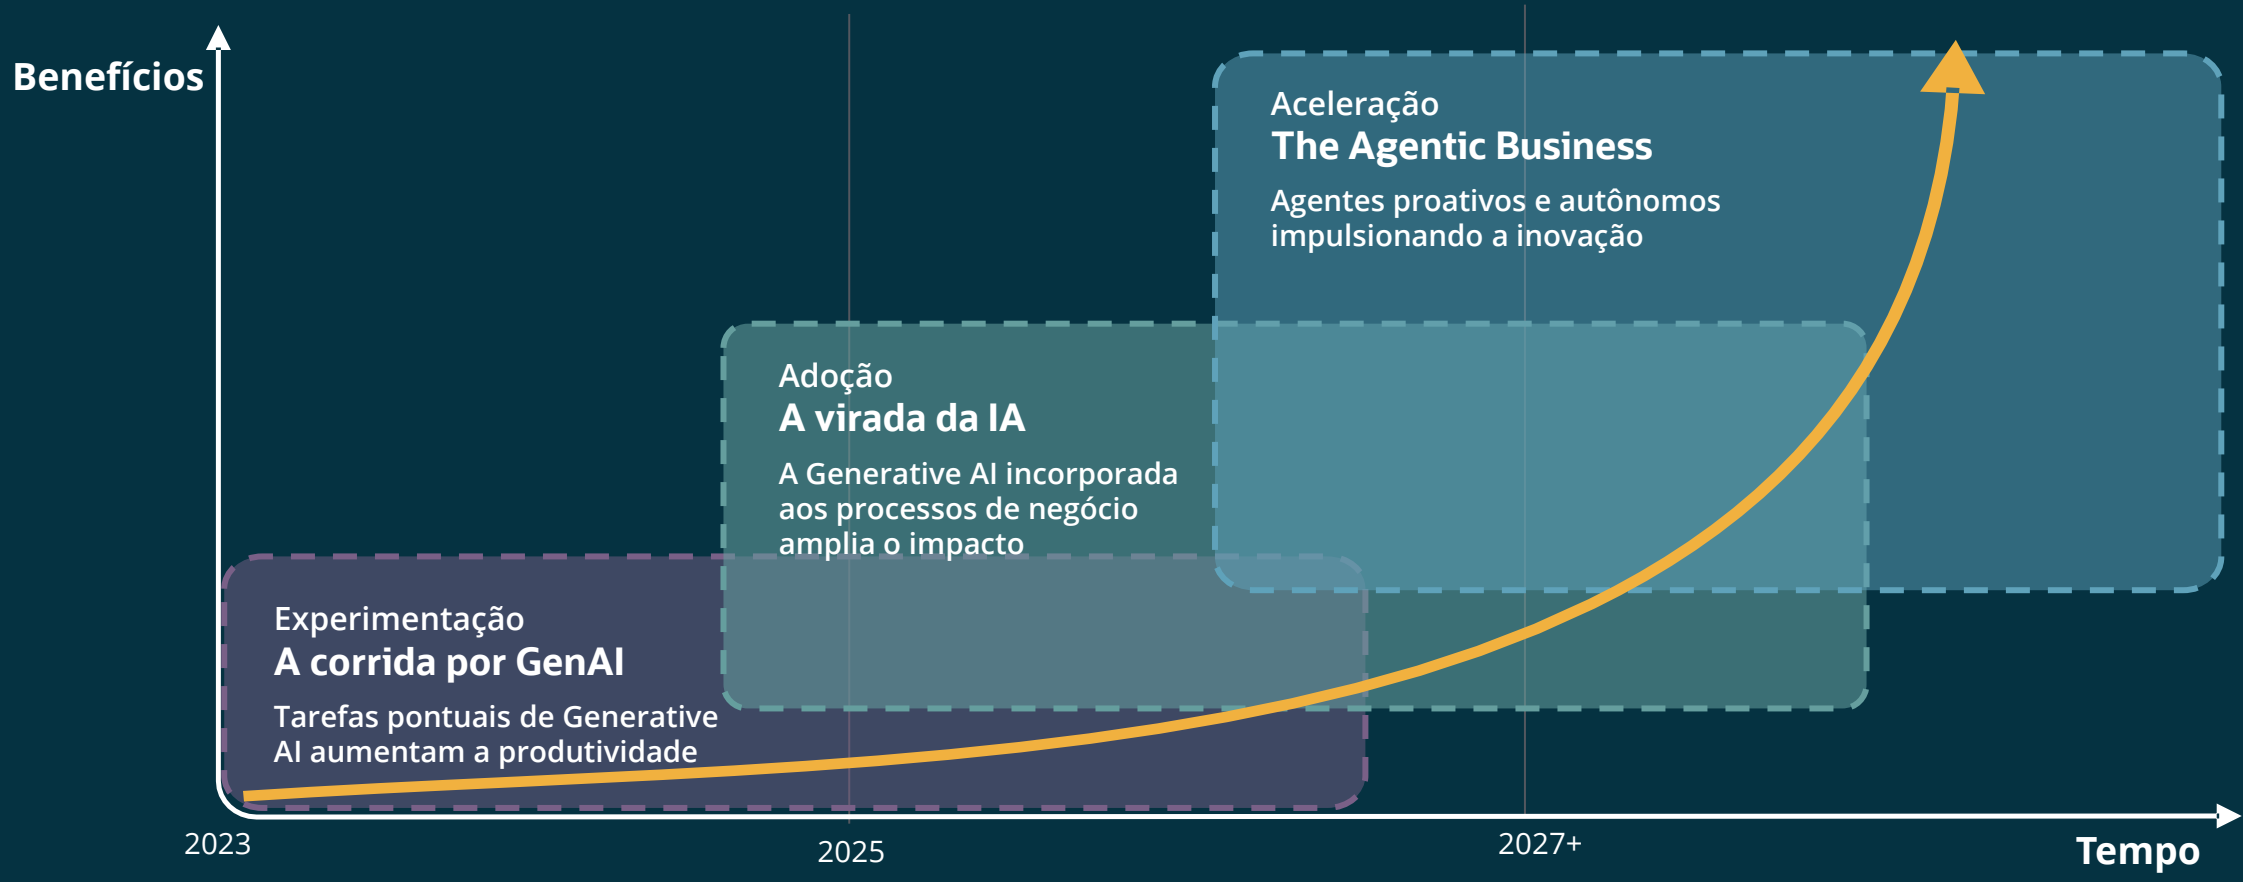
ORACLE

Maturidade de IA

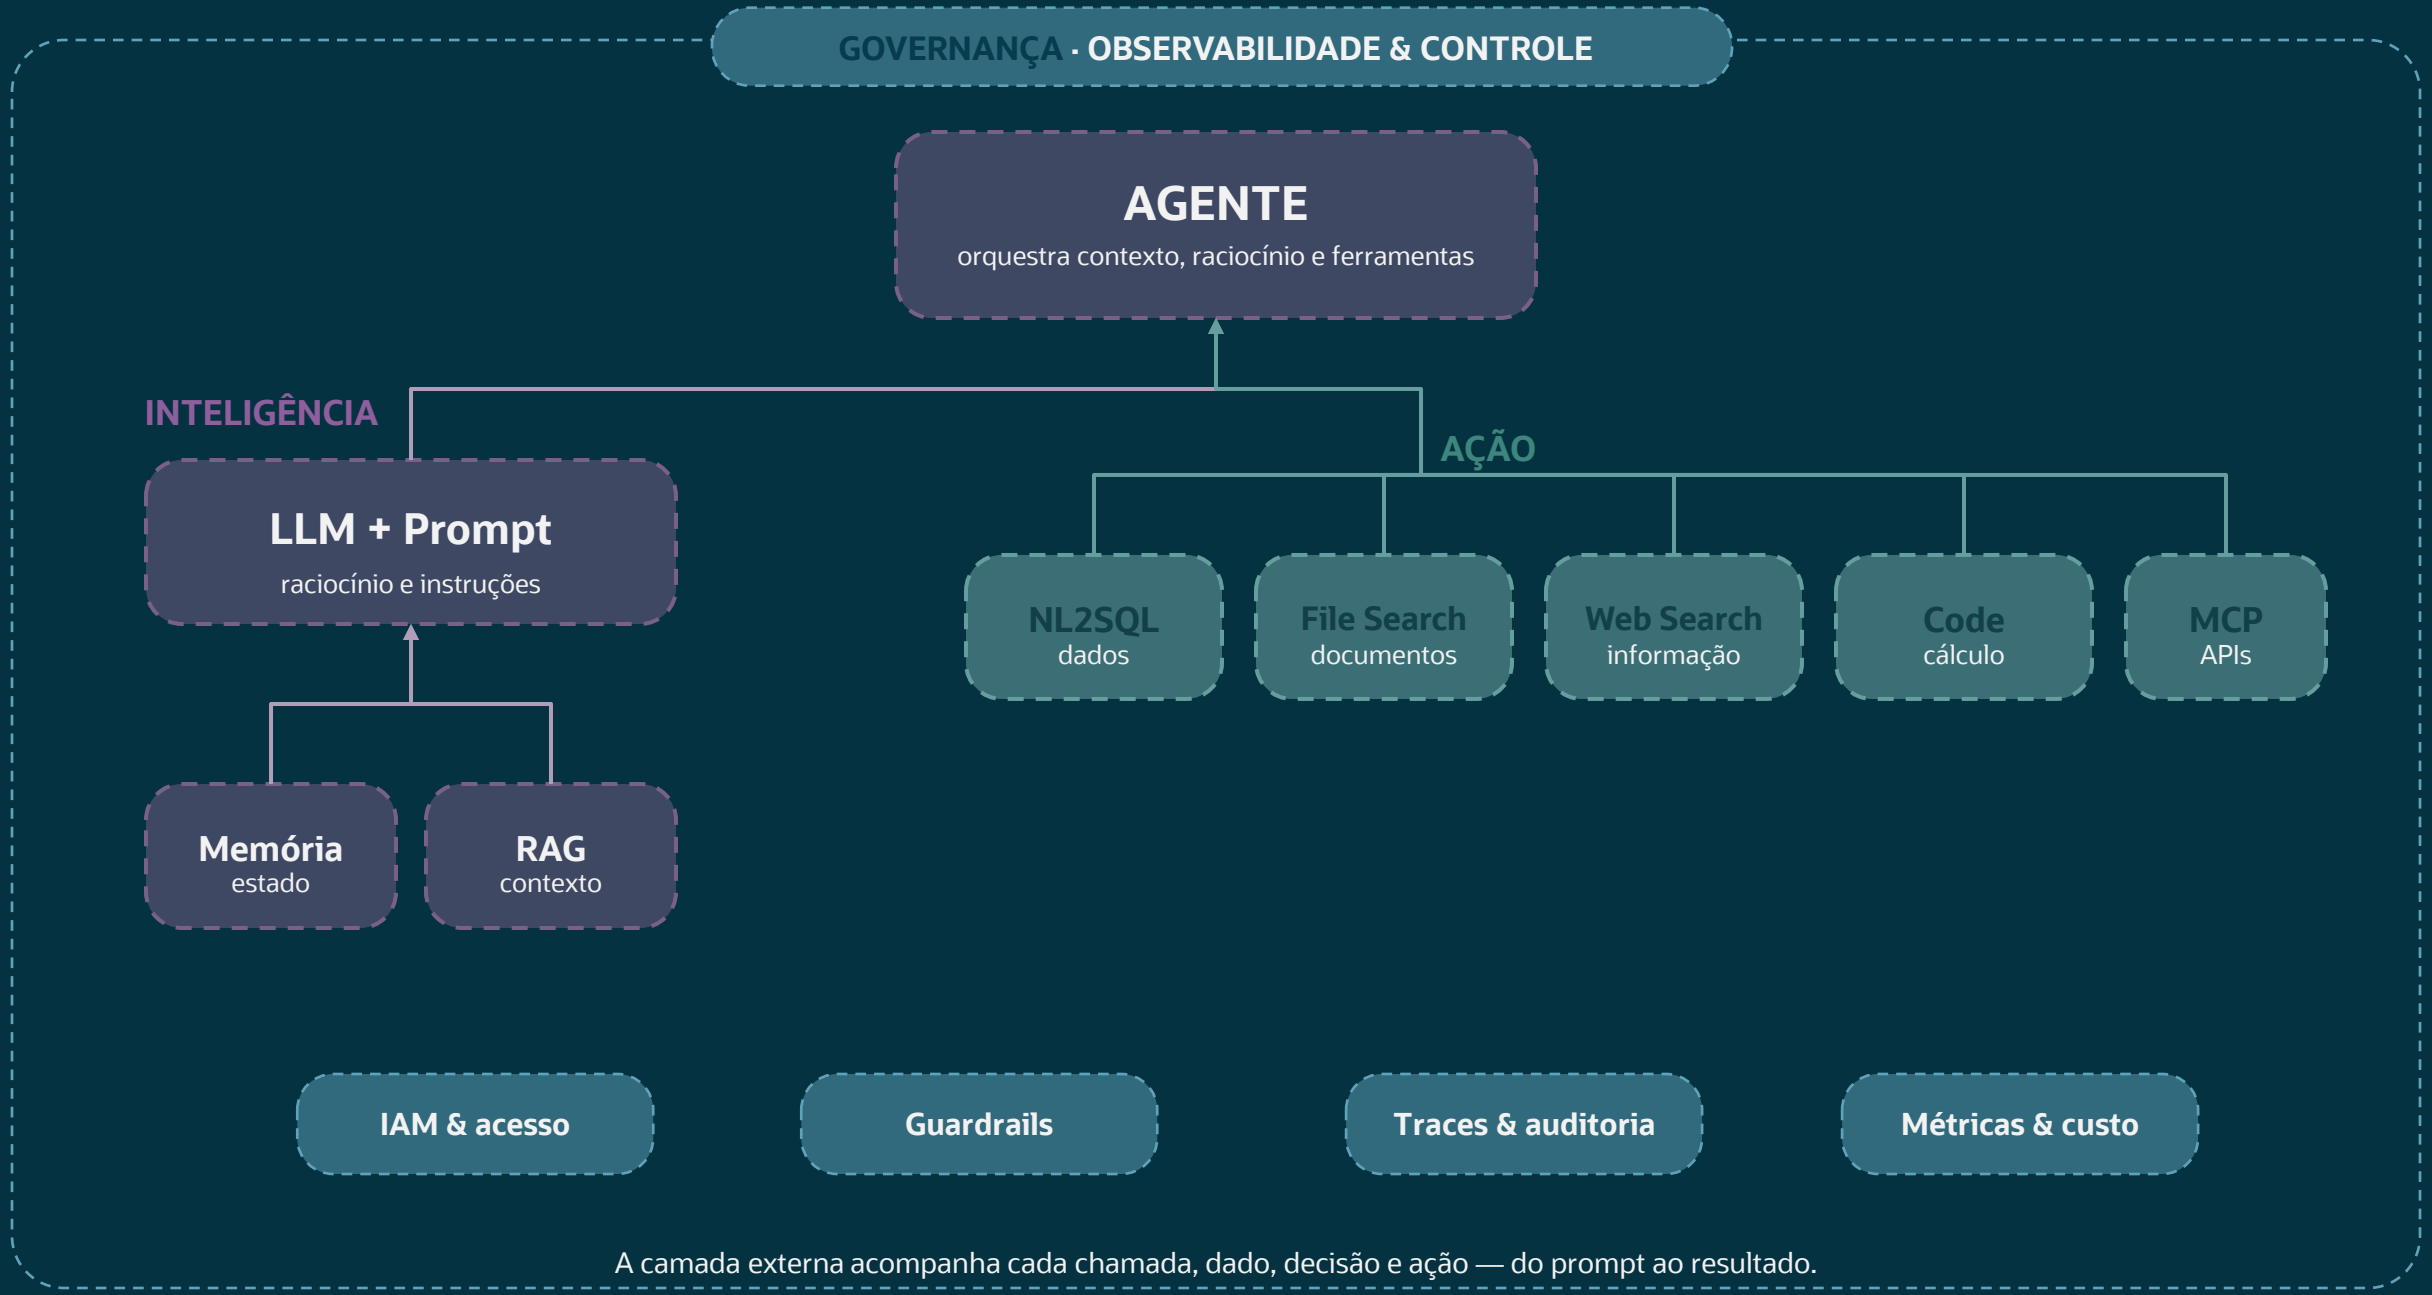
Problemas reais para empresas reais

Amanda Machado
Engenheira de IA

A evolução da IA para empresas: de generative a agentic



Copyright © 2026, Oracle e/ou suas afiliadas



A camada externa acompanha cada chamada, dado, decisão e ação — do prompt ao resultado.

Copyright © 2026, Oracle and/or its affiliates

Ficar preso na corrida por GenAI

Principais desafios empresariais para escalar IA

Cenário de IA fragmentado

5+

Provedores de GenAI utilizados, em medias e grandes empresas, gerando necessidade de **orquestração** e governança da **complexidade**

Ecossistemas fechados e vendor lock-in

<25%

das empresas possuem interoperabilidade de IA entre fornecedores, **limitando flexibilidade** e **inovação**

Ciclos longos

50%

dos pilotos de GenAI **estagnam** antes da produção devido à **falta de automação** e de padrões reutilizáveis

Custo crescente

25-45%

de aumento anual nos custos de **inferência GenAI** quando as cargas de trabalho não são **otimizadas** nem roteadas dinamicamente

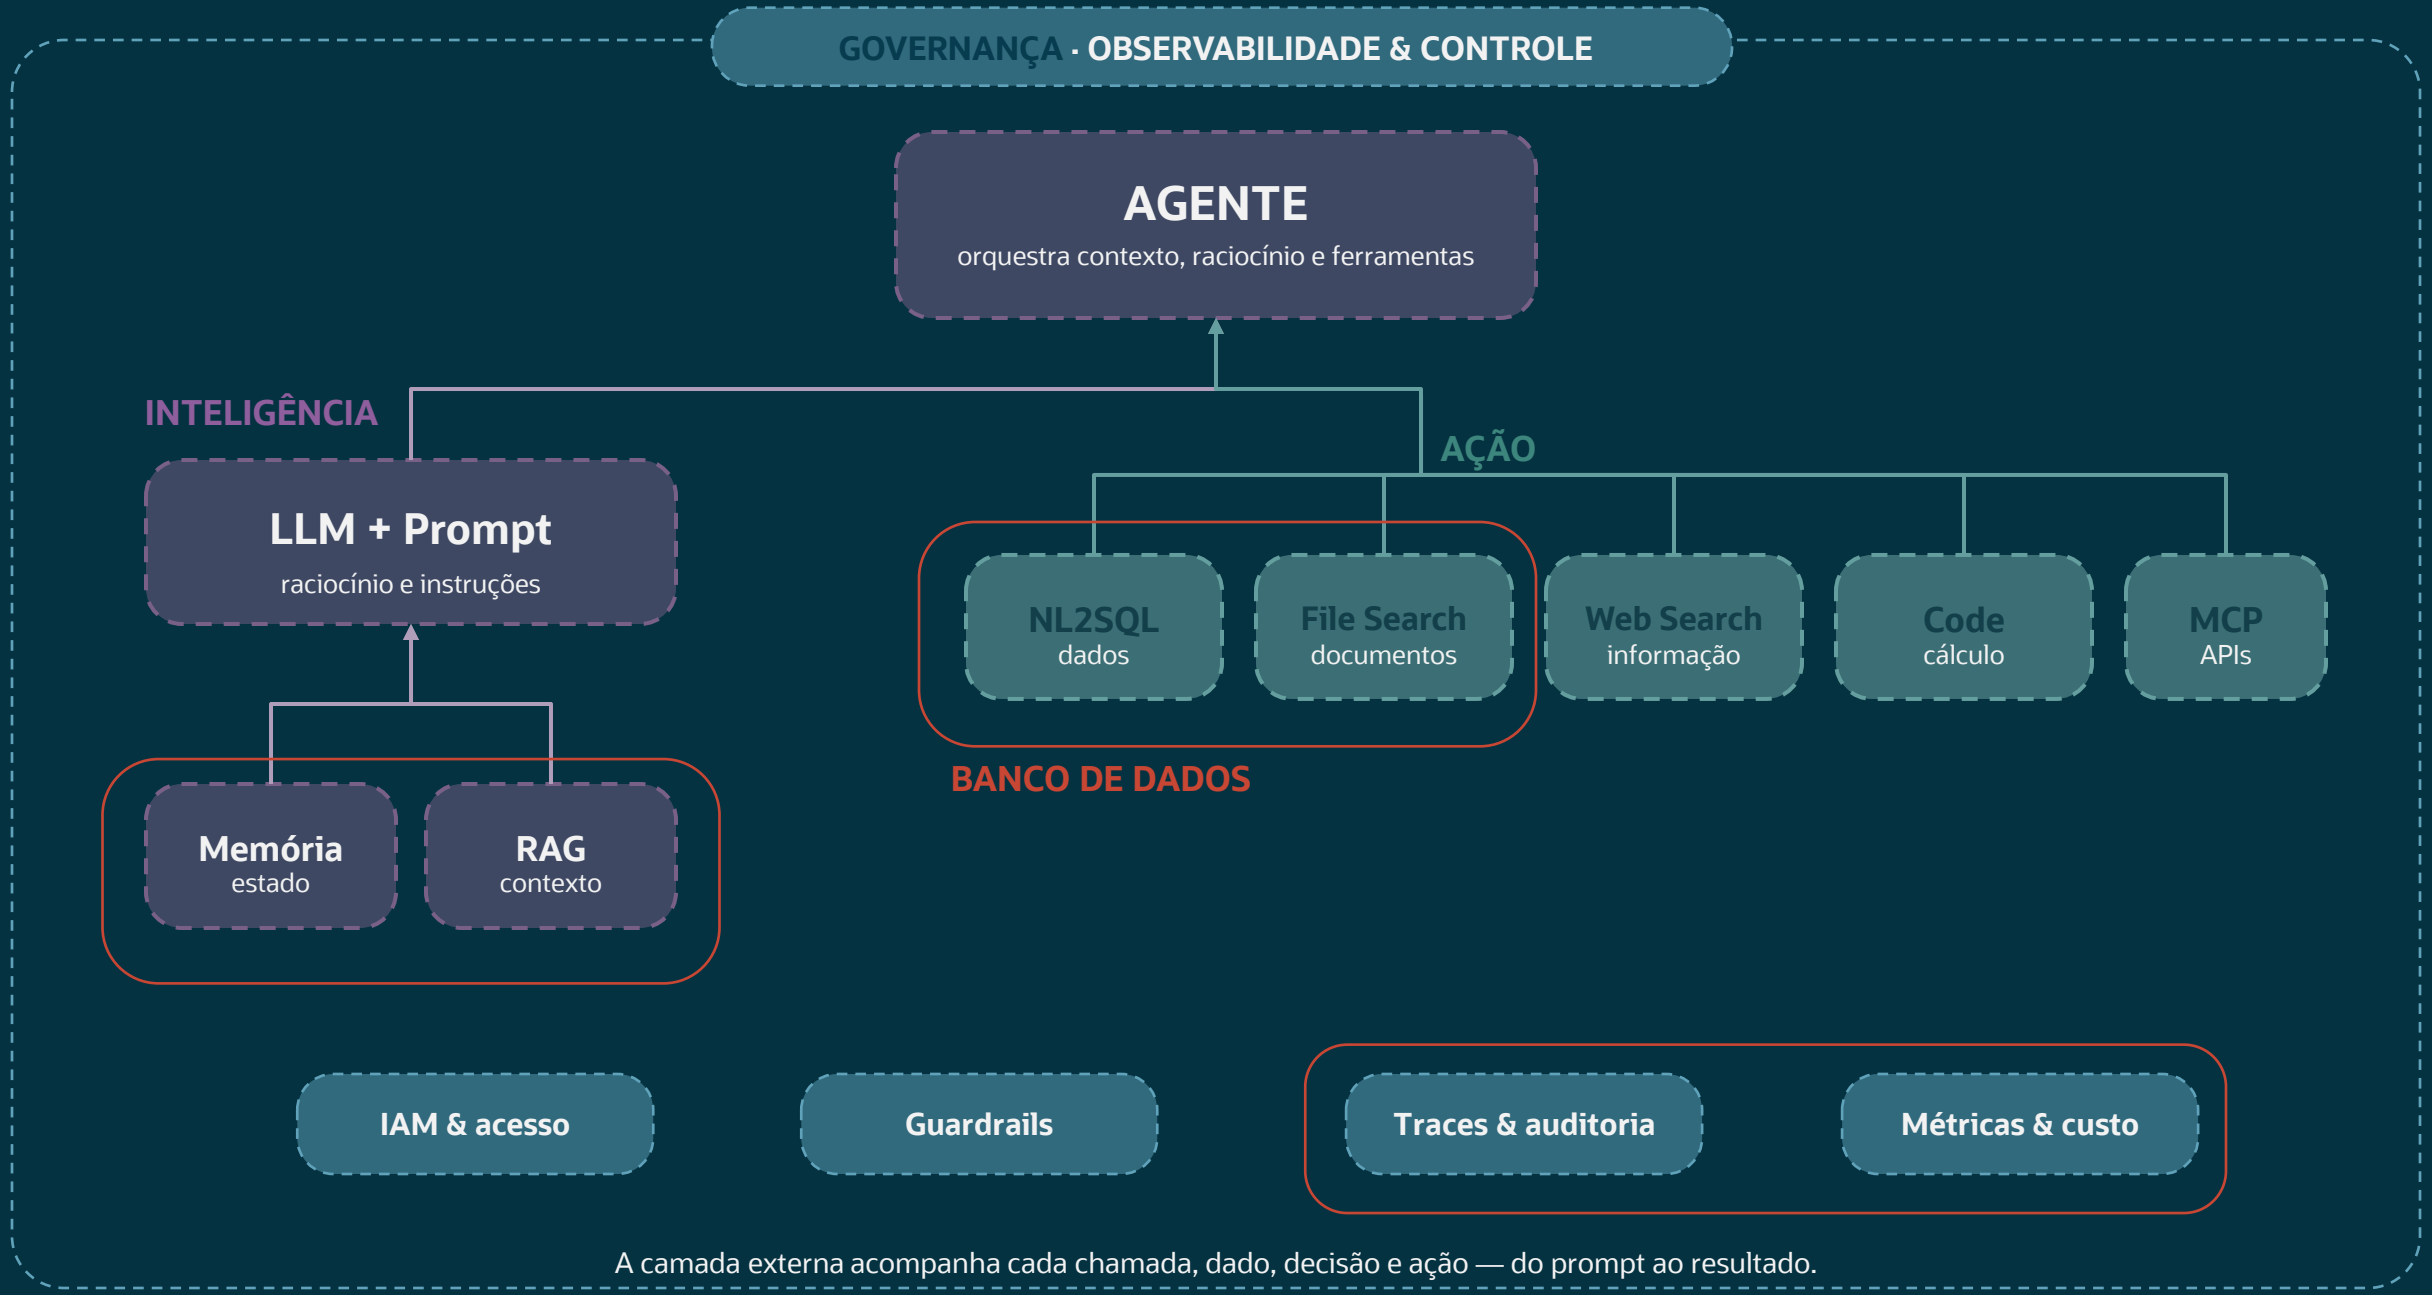
Segurança e conformidade

44%

das organizações relatam **incidentes** relacionados à privacidade de dados ou propriedade intelectual durante pilotos de GenAI

Fonte: pesquisas GenAI da BCG e McKinsey (2024–2025), Oracle BVS

Copyright © 2026, Oracle e/ou suas afiliadas



A camada externa acompanha cada chamada, dado, decisão e ação — do prompt ao resultado.

Copyright © 2026, Oracle and/or its affiliates

1) Dados são o coração

Sem dados bem organizados, AI vira adivinhação sofisticada.

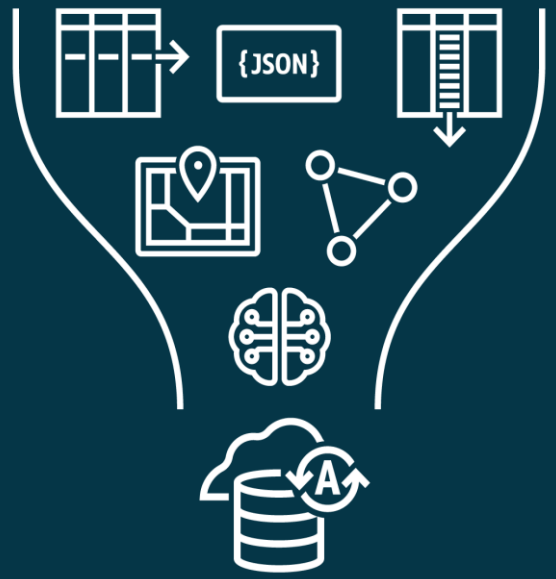


Toda aplicação de AI que funciona em produção tem uma coisa em comum: **um banco de dados forte por trás.**

- Contexto vem dos dados
- Persistência de memória
- Vetores + dados transacionais
- Observabilidade, logs e auditoria

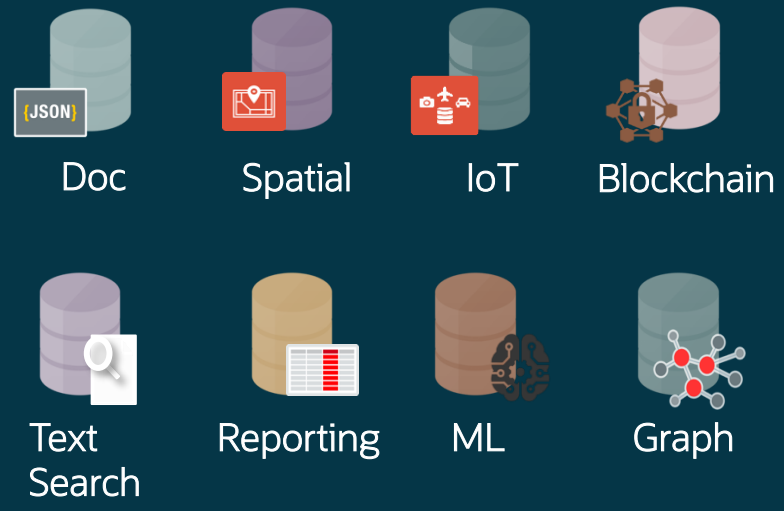
Copyright © 2026, Oracle and/or its affiliates

Um banco de dados



Desenvolvedores e IT focam em **Inovação**

Em vez de bancos de dados proprietários de uso único



Desenvolvedores e IT focam em **Integração**

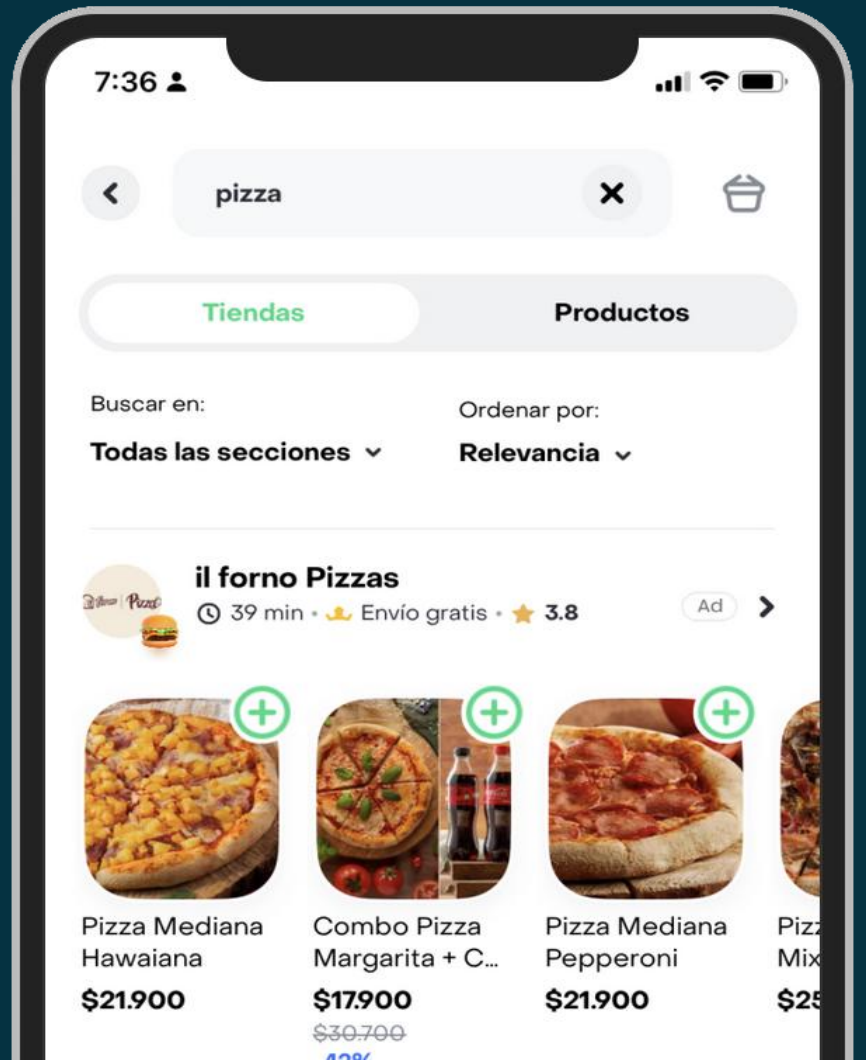
Copyright © 2026, Oracle and/or its affiliates

Caso de uso da Rappi

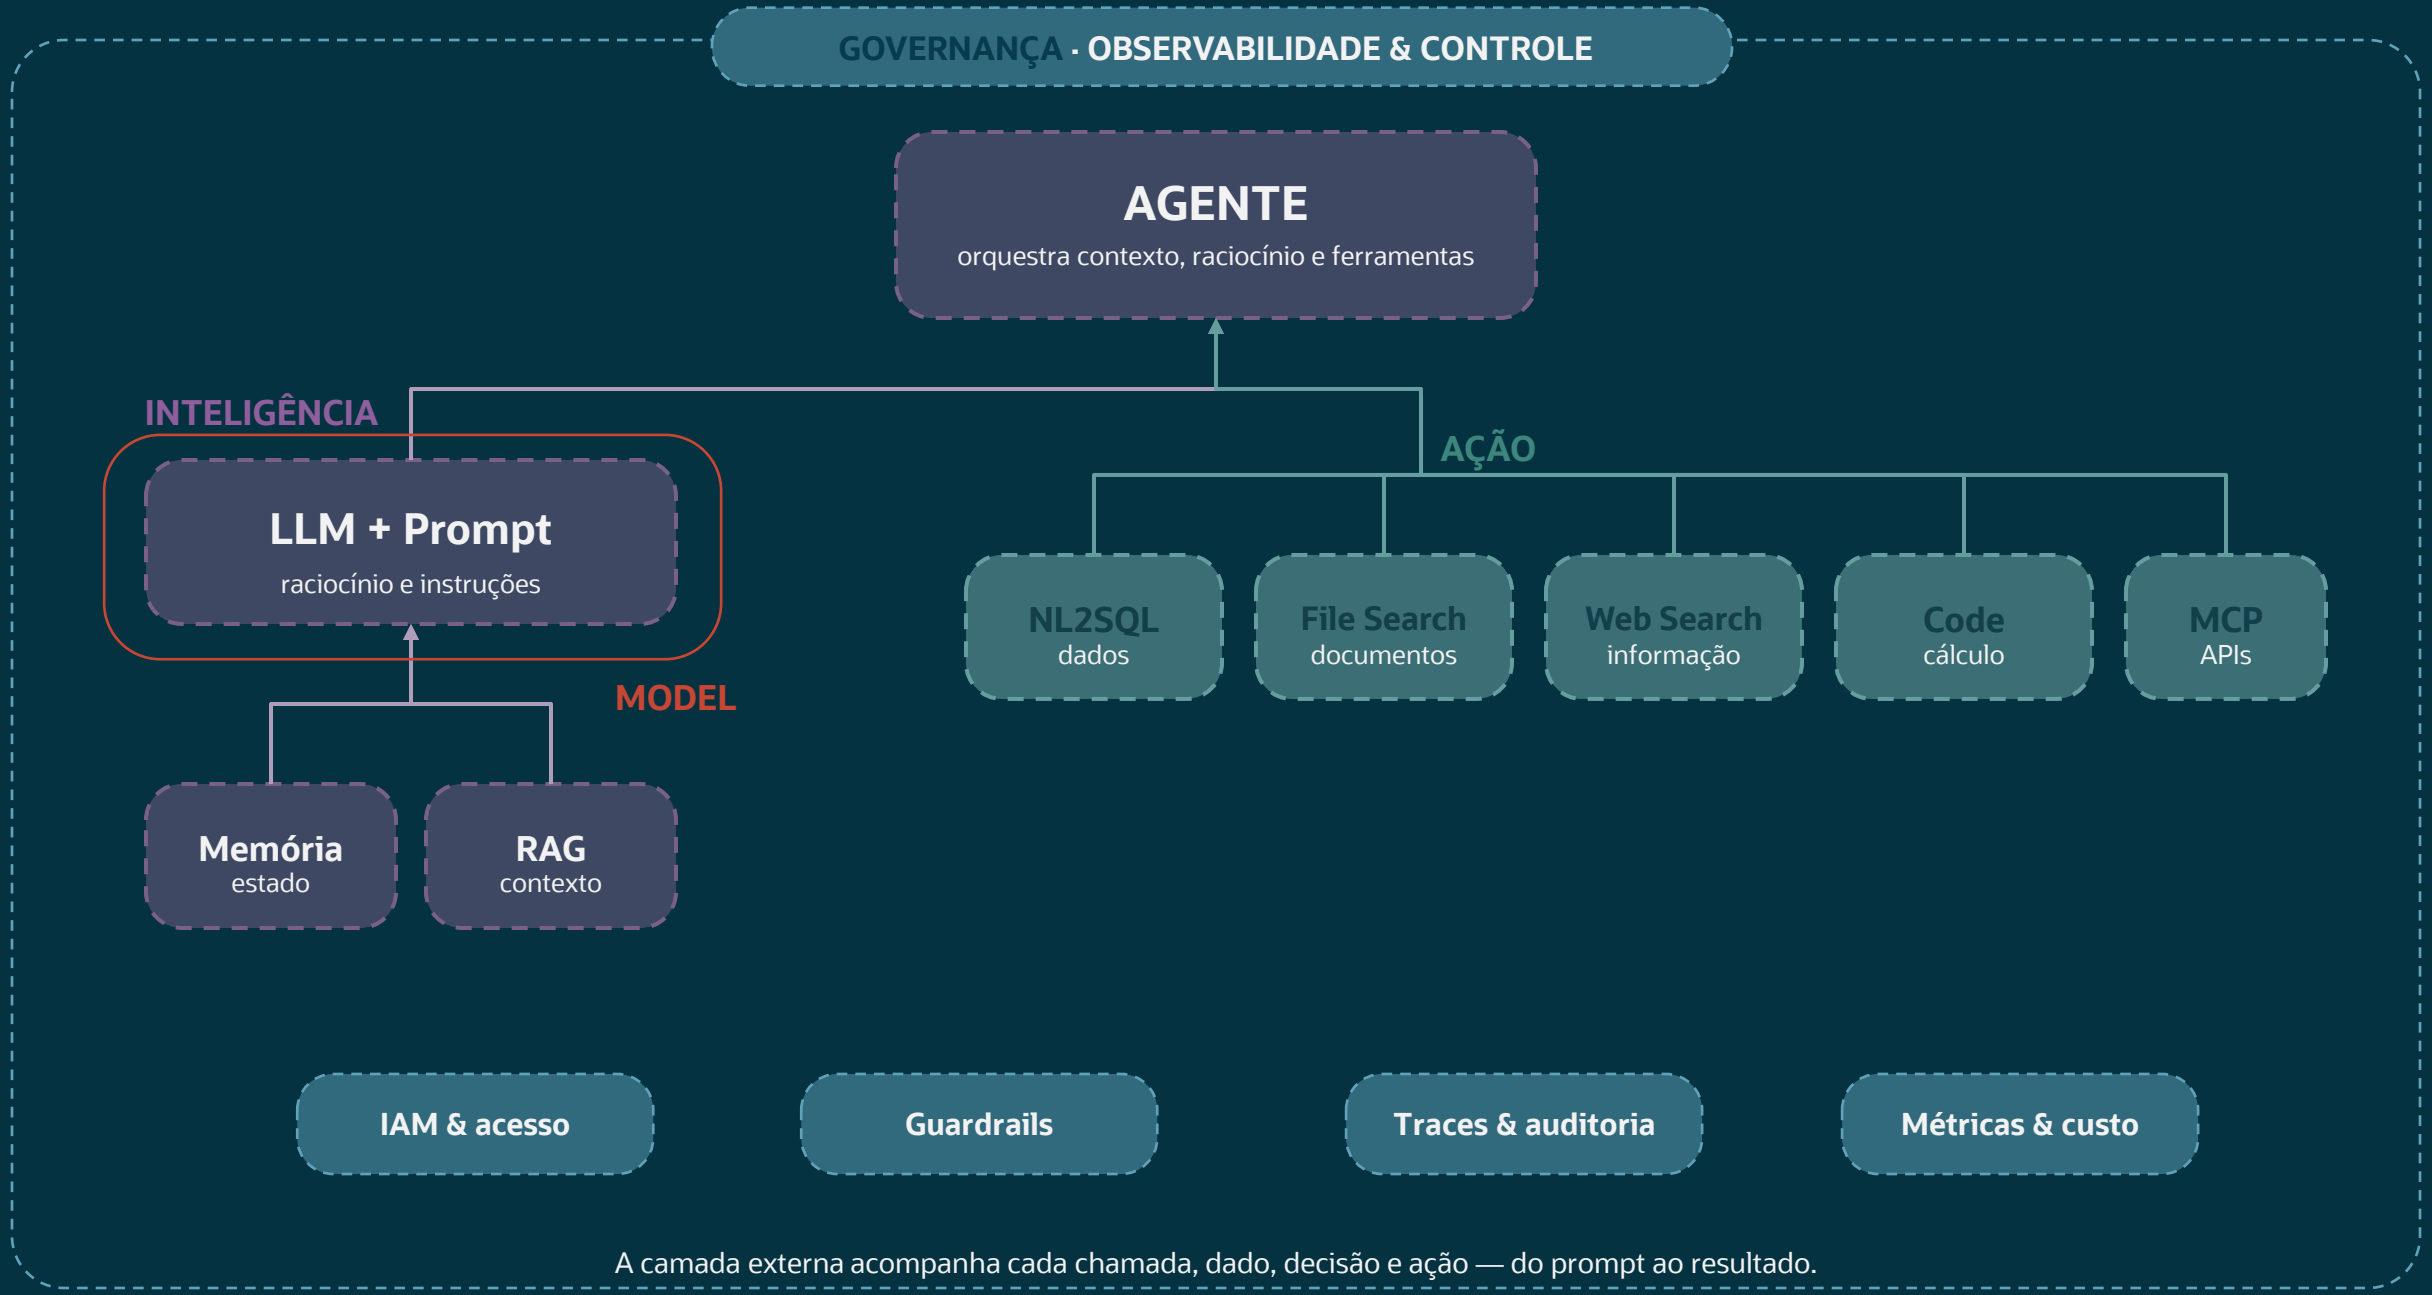
A Rappi é o principal super app de delivery da América Latina, operando em mais de 300 cidades, com milhões de usuários e alto volume transacional diário.

Resultados

- **40% de redução na latência** de buscas
- **25% de aumento na taxa de conversão**
- Automação de workflows estratégicos
- Suporte em tempo real para parceiros
- Processamento eficiente em larga escala



Copyright © 2026, Oracle and/or its affiliates



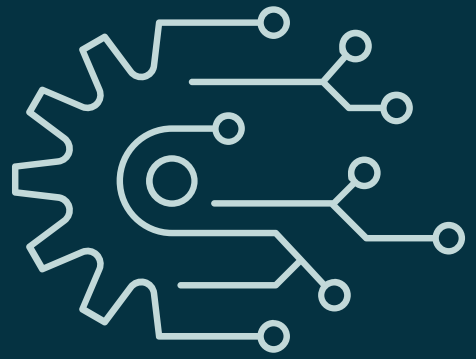
A camada externa acompanha cada chamada, dado, decisão e ação — do prompt ao resultado.

Copyright © 2026, Oracle and/or its affiliates

Modelos

Frontier Models

Modelos de última geração, geralmente disponibilizados por seus provedores como serviços gerenciados.



Modelos abertos

Modelos disponibilizados publicamente, com mais opções de execução e adaptação conforme a necessidade.

Grok

OpenAI

Gemini

Z.ai

Qwen

NVIDIA

KIMI

deepseek

Copyright © 2026, Oracle and/or its affiliates

O maior risco dos modelos hoje é a dependência operacional

Lock-in invisível

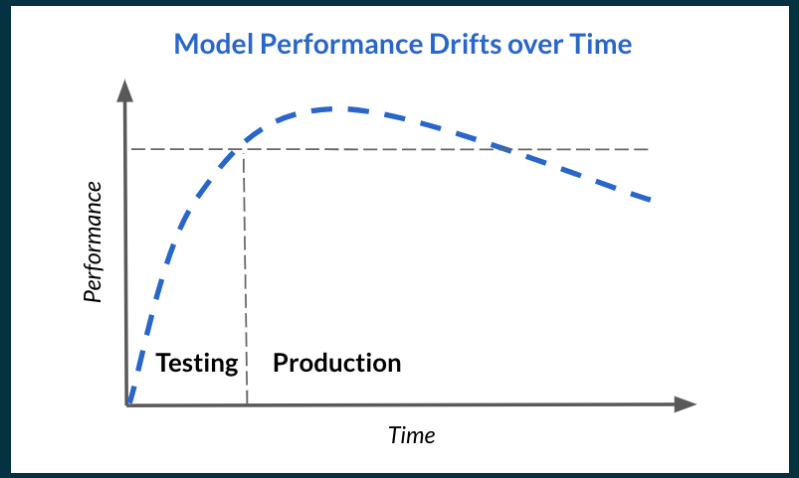
O verdadeiro contrato não está apenas no preço: está no comportamento do modelo, na API, no ciclo de vida, no contexto permitido e no roadmap do fornecedor.

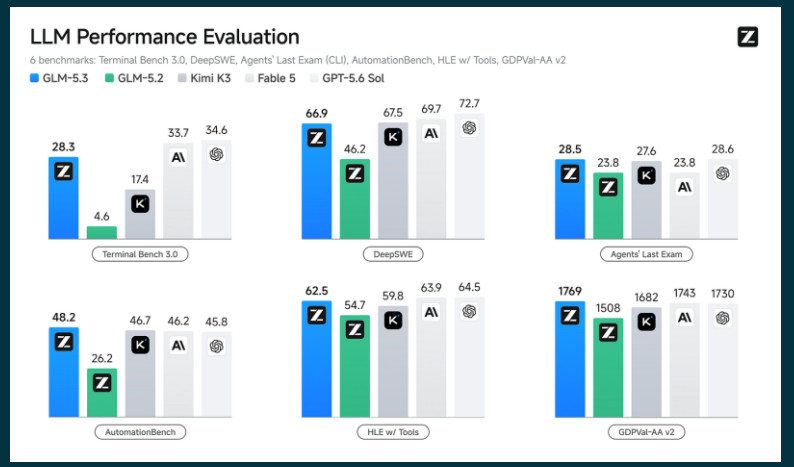
Modelos abertos avançam

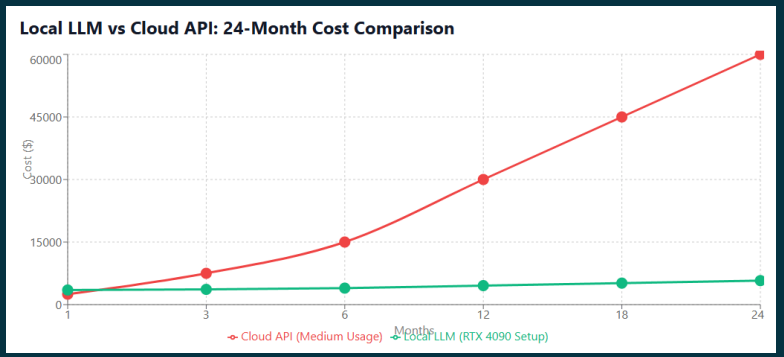
Modelos open-weight e open-source já são suficientemente capazes para muitas cargas de trabalho empresariais; a decisão passa a considerar workload, custo, controle e licenciamento.

Previsilibilidade de custo

Em modelos locais, o custo deixa de ser calculado por volume de tokens e passa a estar associado à infraestrutura: capacidade de GPU, memória, consumo e tempo de operação da máquina.



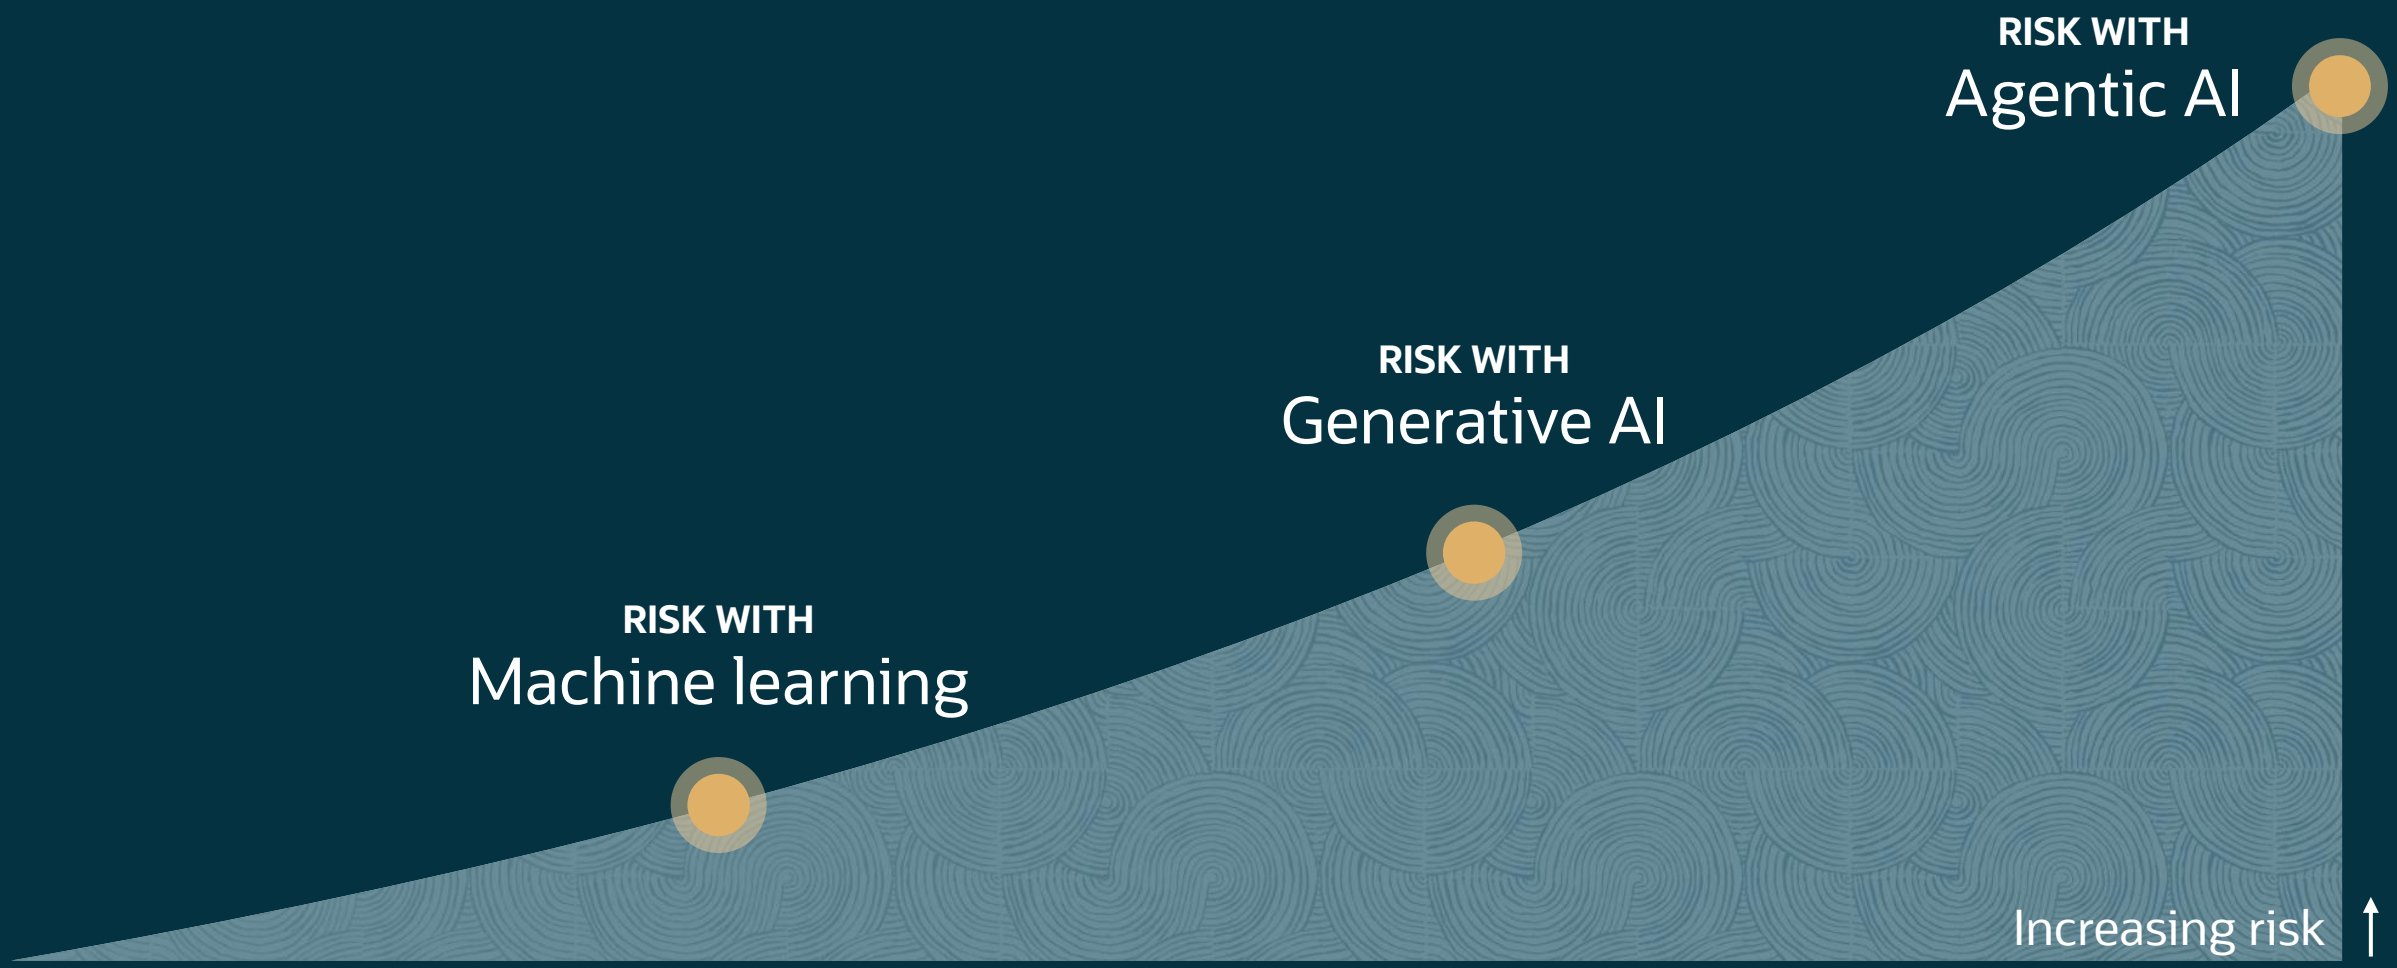




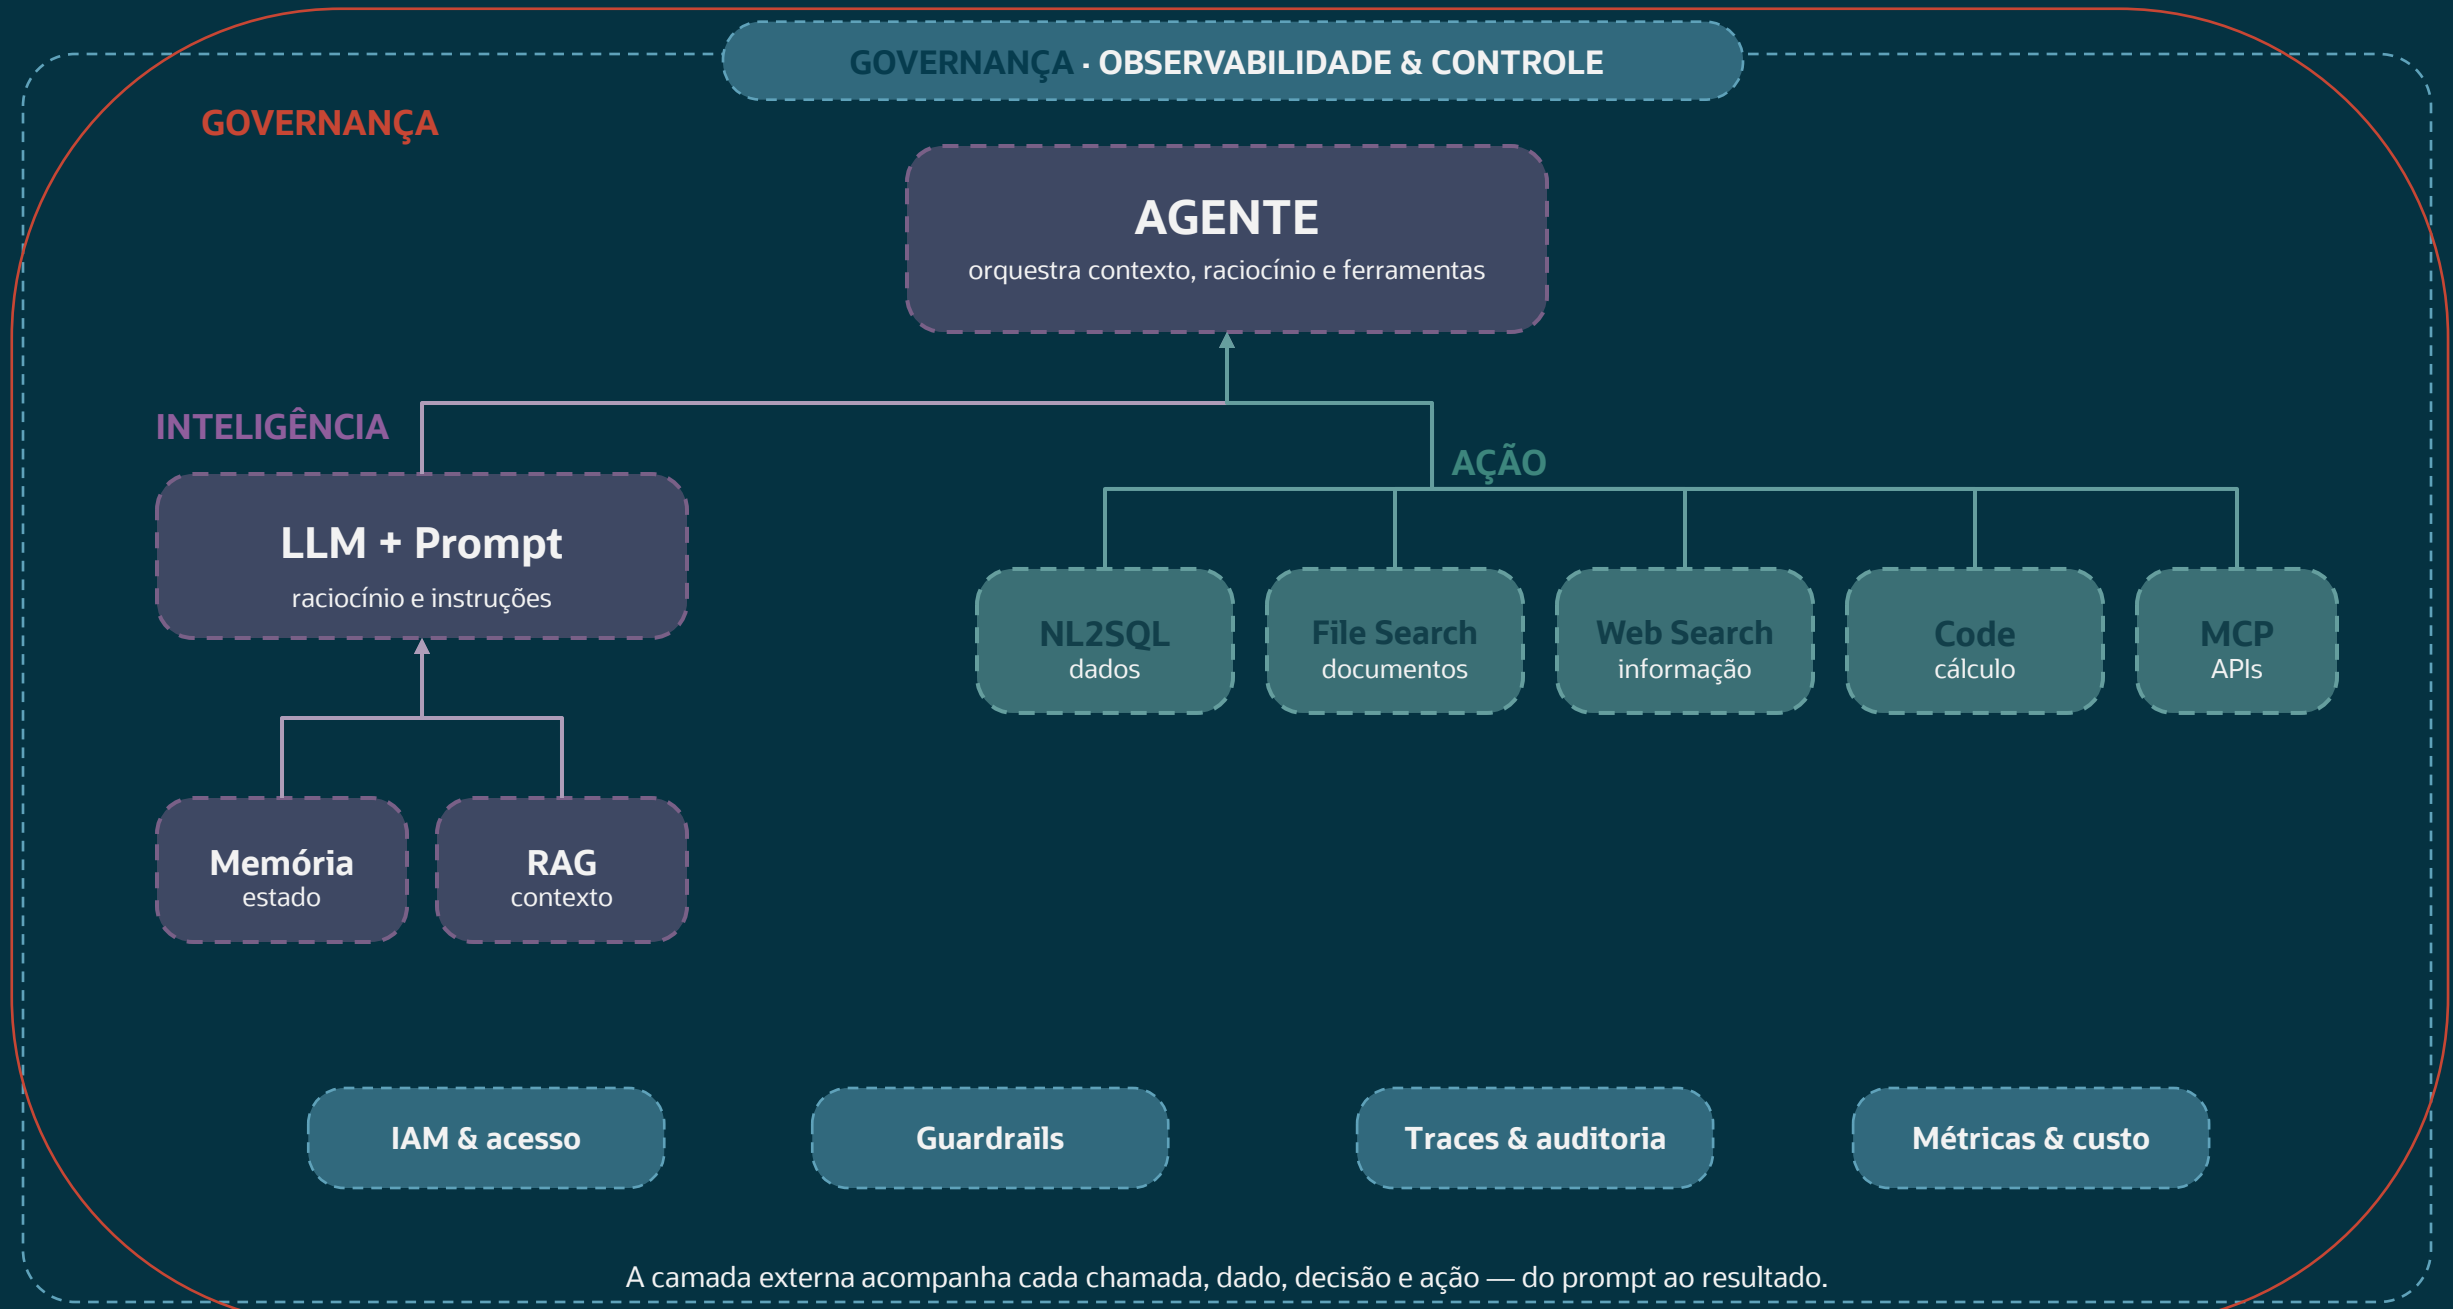
Copyright © 2026, Oracle and/or its affiliates

4) Segurança, soberania e governança

Quanto maior impacto maior o risco



Copyright © 2026, Oracle and/or its affiliates



A camada externa acompanha cada chamada, dado, decisão e ação — do prompt ao resultado.

Copyright © 2026, Oracle and/or its affiliates

A segurança eficaz em IA é multifacetada



Proteja os dados

Proteja seus dados confidenciais

Proteja o acesso

Aproveite recursos nativos de segurança e observabilidade

Controles adicionais de segurança

Guardrails capazes de filtrar conteúdo nocivo, prevenir vazamento de dados e muito mais

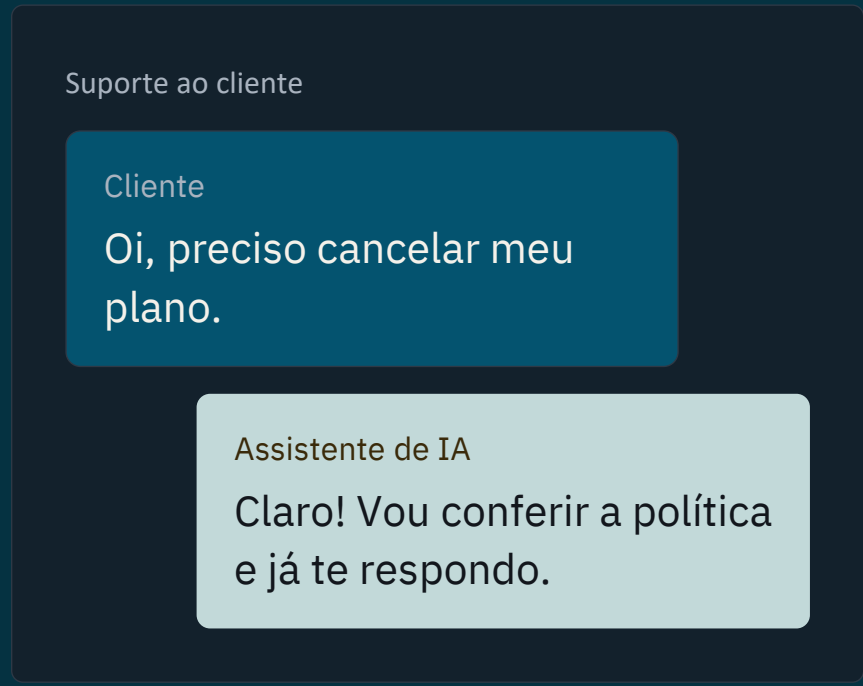
Copyright © 2026, Oracle e/ou suas afiliadas

E QUANDO ESCALA?

Sua IA sobrevive a um milhão de conversas?

A IA responde bem e então o uso cresceu 10 vezes

Qual hipótese você investigaria primeiro para proteger a margem?



Copyright © 2026, Oracle and/or its affiliates

A conversa que o cliente vê

Cliente

Comprei há 18 dias e o serviço ficou fora do ar por 26 horas. Posso cancelar e receber meu dinheiro de volta?

Assistente de IA

Como a interrupção passou de 24 horas, você tem direito a reembolso. Vou registrar o cancelamento agora.

1

interação, para quem está do outro lado da tela

Uma pergunta, uma resposta

Copyright © 2026, Oracle and/or its affiliates

A execução que o cliente não vê

Cliente

Comprei há 18 dias e o serviço ficou fora do ar por 26 horas. Posso cancelar e receber meu dinheiro de volta?

01
Classificar pedido
Define o tipo de solicitação

02
Consultar regra
Busca a política aplicável

03
Consultar ferramentas
Buscar informações ou fazer ações

04
Redigir resposta
Escreve a mensagem ao cliente

05
Guardrails
Conferir regras e politicas da conversa

Uma resposta. Cinco chamadas ou mais.

Copyright © 2026, Oracle and/or its affiliates

Onde o custo se multiplica



Histórico reenviado

Cada mensagem nova leva junto todas as anteriores.



Contexto irrelevante

A política inteira viaja, mesmo para uma dúvida simples.



Tentativas repetidas

Respostas refeitas até passar numa revisão.



Chamadas desnecessárias

Etapas que repetem trabalho que já estava feito.

Copyright © 2026, Oracle and/or its affiliates

O QUE AS EMPRESAS MAIS MADURAS ESTÃO TRABALHANDO PARA ESCALA?

Decisões de arquitetura que trazem maturidade e escala para seu agente

Copyright © 2026, Oracle and/or its affiliates

LLM

Diminuir custo de inferência por token

Memória

mantendo apenas informações relevantes

Cache

evitar inferências desnecessárias

Router

melhor relação entre custo e capacidade

Especialista

fluxos específicos para cada tarefa

Banco

reduz etapas de descoberta e correção

Copyright © 2026, Oracle and/or its affiliates

Memória: reconstruir contexto, não reenviar histórico

Separe o estado da conversa do conhecimento persistente e selecione só o necessário a cada chamada.

CURTO PRAZO / THREAD

Histórico recente
4 últimos turnos

→

Resumo evolutivo
decisões e pendências

→

Prompt
contexto compacto

LONGO PRAZO / USUÁRIO

Fatos persistentes
preferências + fatos

→

Busca top-k
filtra usuário + relevância

→

Prompt
só fatos úteis

EXEMPLO · TURNO 12

3.600

tokens de histórico completo

↓

1.450

turnos recentes + resumo

≈ 60% menos histórico

Copyright © 2026, Oracle and/or its affiliates

Banco convergente + ontologia: dar sentido ao NL2SQL

O mapa semântico já entrega termos de negócio, relações e restrições antes de gerar a consulta.

EXEMPLO - “RECEITA”

“Receita por região no último trimestre”

Camada semântica

“receita” =
SUM(valor_pago)
join pedido → região

→

Contexto NL2SQL

views + colunas + grão
regras e privilégios

→

Gerar + validar SQL

somente leitura; limites
e checagem de acesso

→

Banco convergente

relacional + JSON +
vetores no mesmo engine

Sem mapa: descobrir tabelas → inspecionar colunas → tentar JOIN → corrigir SQL

Com mapa: contexto selecionado → SQL validado → execução autorizada

SQL correto na 1ª tentativa · p95

Copyright © 2026, Oracle and/or its affiliates

Sem ontologia



Com ontologia



Copyright © 2026, Oracle and/or its affiliates

Ontologia na prática

Conceito: receita
Expressão aprovada: SUM(payment.amount)
Filtro obrigatório: payment.status = 'CONFIRMED'

Conceito: cliente premium
Filtro: customer_segment.segment_code = 'PREMIUM'

Join path aprovado:
orders.customer_id = customer.customer_id
customer.address_id = address.address_id
address.region_id = region.region_id
orders.order_id = payment.order_id

Coluna temporal:
orders.order_date

Objetos permitidos:
sales_orders_view
customer_segment
region



Copyright © 2026, Oracle and/or its affiliates

Especialistas: condensar um trabalho recorrente

Um workflow por domínio conhece entradas, ferramentas permitidas e resposta esperada.

PERGUNTA - “ONDE ESTÁ MEU PEDIDO?”

Agente genérico

achar cliente → **listar pedidos** → **ler status** → **consultar política**

4 decisões de tool + retorno ao modelo a cada passo

Especialista de pedidos

Roteamento por intenção → **consultar_contexto_pedido**
compõe dados + política no backend → **Validar e responder**

Copyright © 2026, Oracle and/or its affiliates

Cache: escolher o que pode ser reutilizado

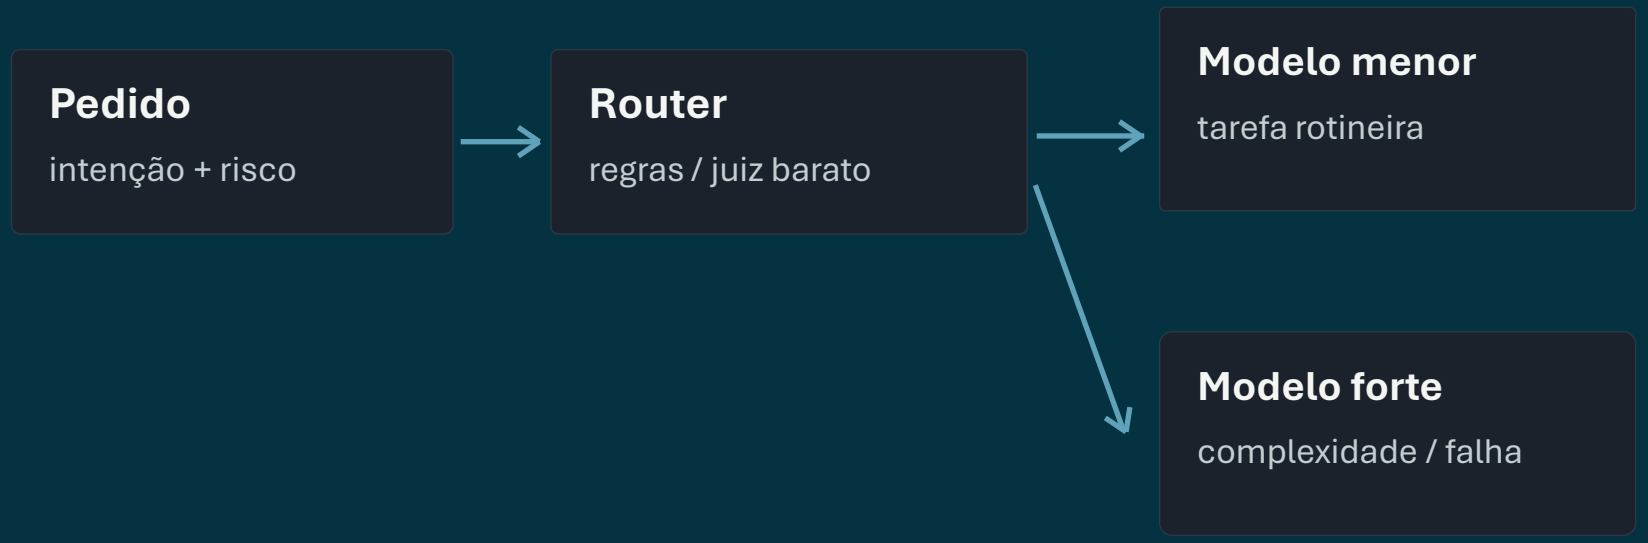
Cache de resposta evita uma inferência; cache de prefixo reaproveita prefill, mas ainda gera uma resposta.



Copyright © 2026, Oracle and/or its affiliates

Router: gastar modelo forte onde ele muda o resultado

Um modelo menor atende o volume frequente, casos difíceis escalam por política ou por avaliação.



US$ 11,45
só modelo frontier

US$ 3,00
roteado / −74% custo

acurácia 86% → 80%

Copyright © 2026, Oracle and/or its affiliates

E A GPU? E MODELOS LOCAIS?

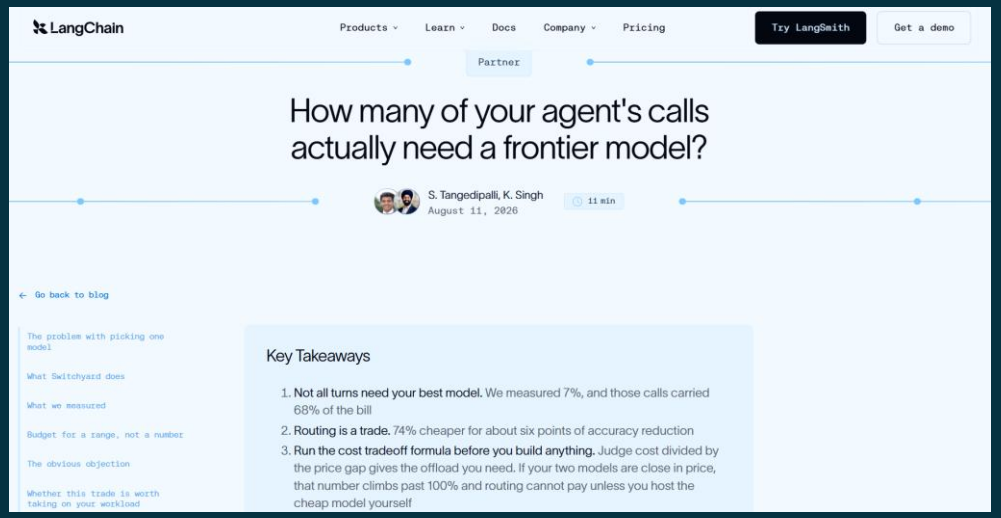
A infraestrutura passa a ser uma decisão quando conhecemos a carga

Antes de dimensionar capacidade: quantas conversas, quantas chamadas, quanto contexto?

Copyright © 2026, Oracle and/or its affiliates

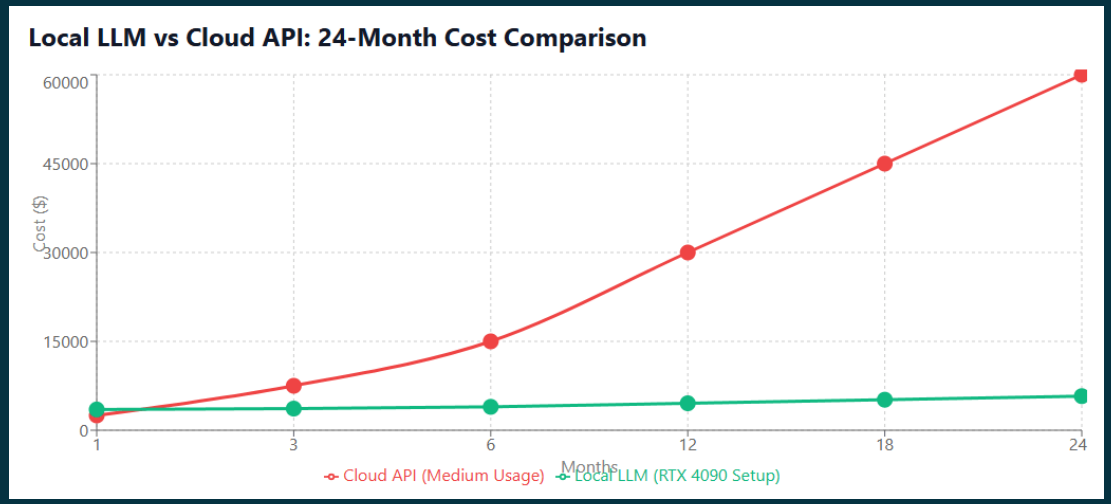
Na capacidade dedicada, ociosidade entra na conta

custo efetivo = horas pagas ÷ tokens gerados



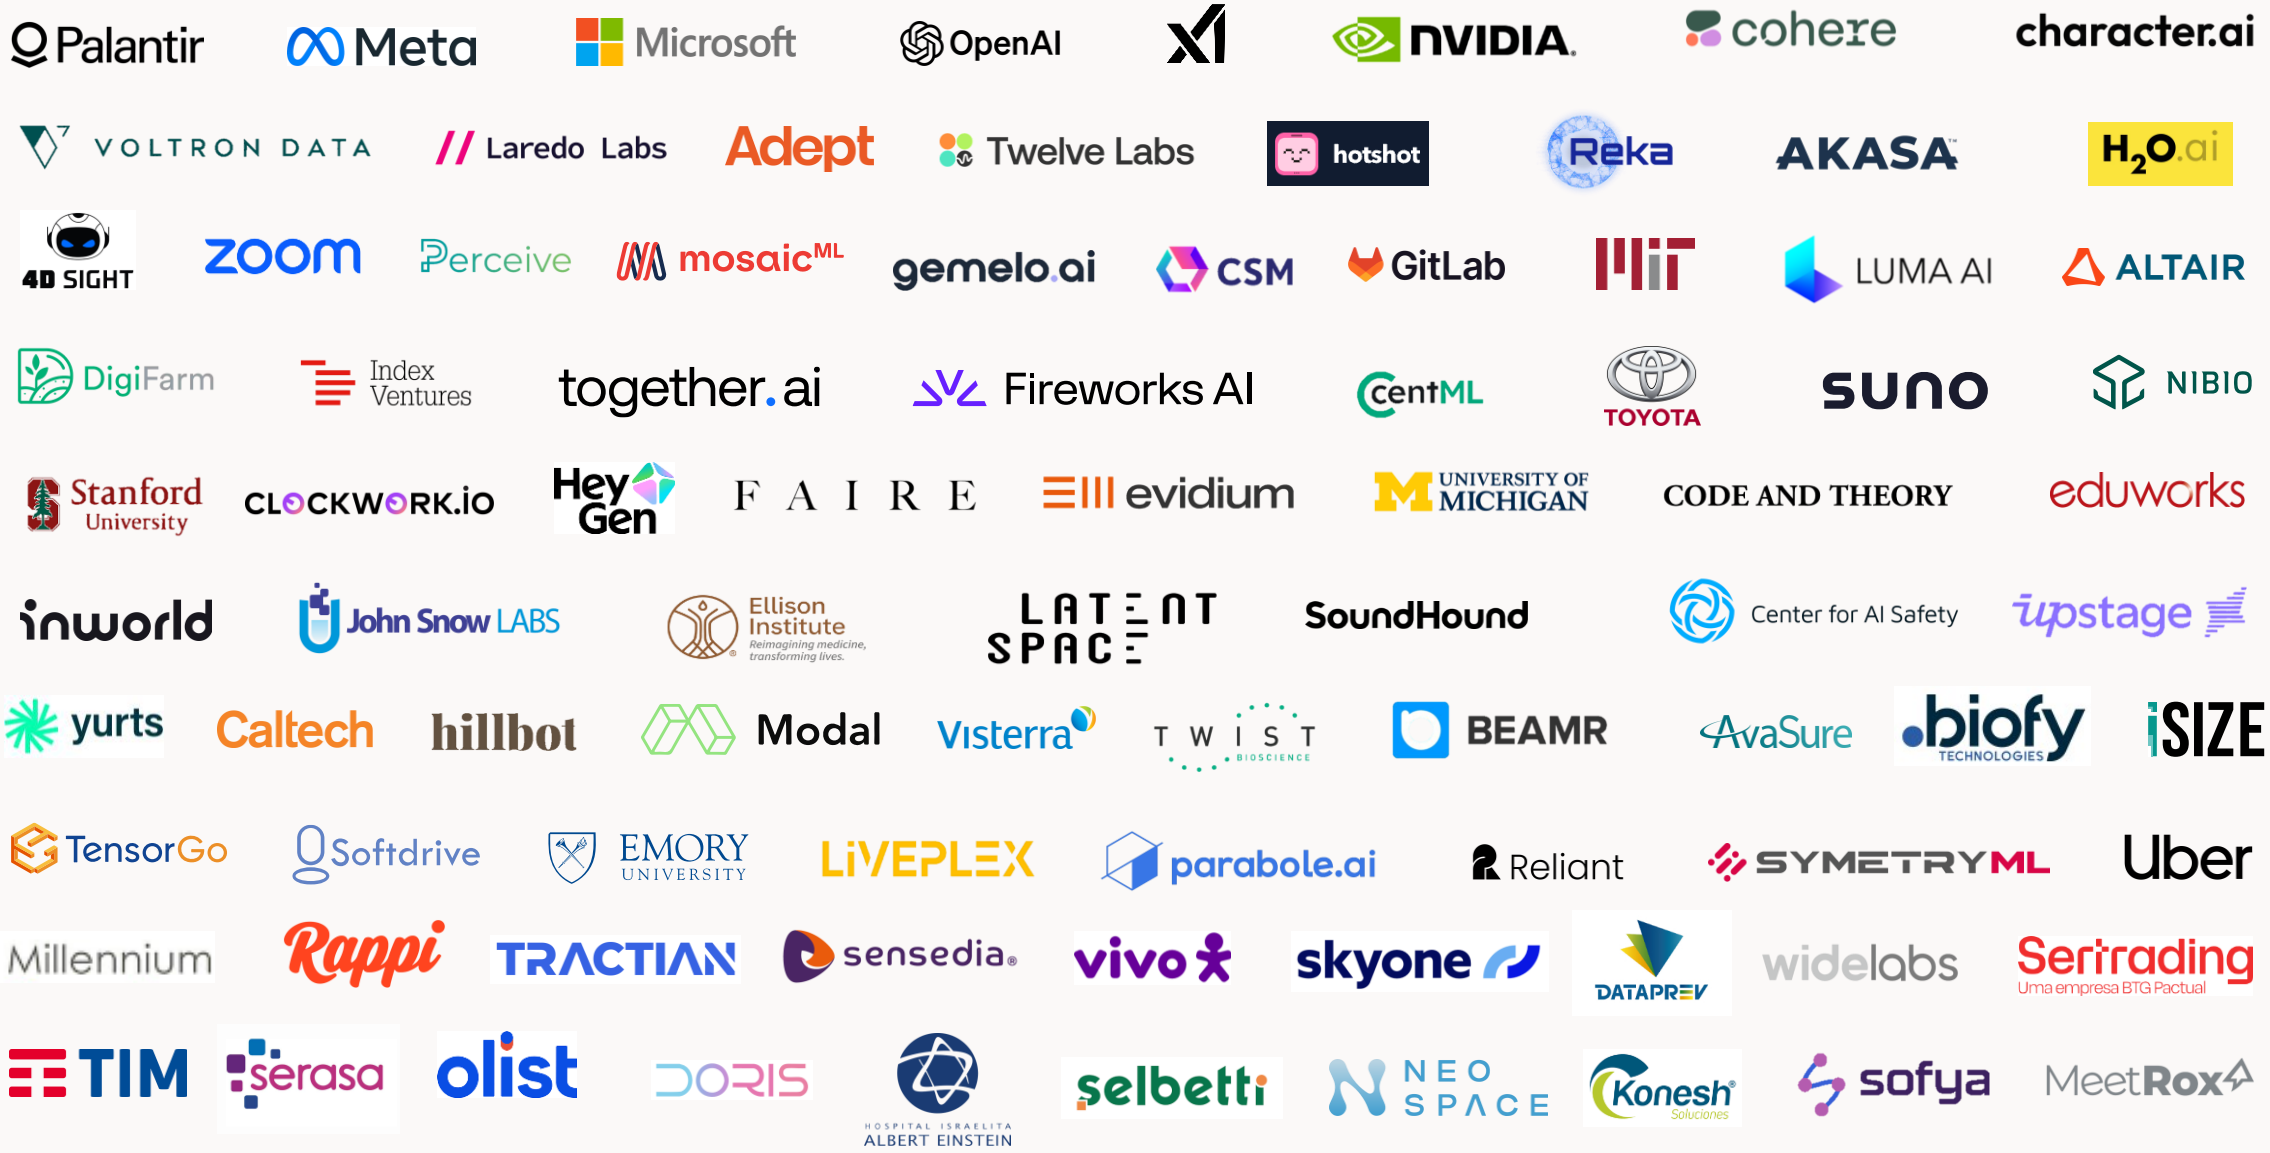
Só 7% das chamadas foram ao frontier, consumiram 68,4% do gasto roteado.

Source: How many of your agent's calls actually need a frontier model?



Pode trazer previsibilidade e as vezes até economia financeira, mas lembre-se que é um recurso físico, apenas para modelos abertos.

Copyright © 2026, Oracle and/or its affiliates



Copyright © 2026, Oracle y/o sus afiliadas



Obrigada



Amanda Machado
Engenheira de IA
Oracle

LinkedIn

AI Solution Engineer | Artificial Intelligence | Machine Learning | Generative AI | Agents AI | Cloud

Copyright © 2026, Oracle e/ou suas afiliadas


ORACLE